

PROYECTO EVALUATIVO DE APRENDIZAJE AUTOMATICO

Segunda Entrega

Segmentación mediante detección de patrones en población adulta en el consumo de psicofármacos con fines terapéuticos

Descripción del dataset final

Para el desarrollo del presente proyecto se construyó un dataset integrado orientado al análisis de patrones de consumo de psicofármacos con fines terapéuticos en población adulta. El objetivo de esta base de datos es servir como insumo para la aplicación de técnicas de Aprendizaje Automático no supervisado, específicamente métodos de segmentación o clustering que permitan identificar perfiles de consumo similares entre los individuos.

El dataset final fue generado a partir de la integración de tres bases de datos públicas pertenecientes a la encuesta Medical Expenditure Panel Survey (MEPS). Cada registro del dataset representa a una persona encuestada y reúne información demográfica, socioeconómica, sanitaria y farmacológica.

La unidad de análisis del dataset corresponde a individuos adultos participantes de la encuesta.

Cantidad de instancias

El dataset final contiene aproximadamente 27.805 instancias, donde cada fila representa una persona identificada mediante la variable DUPERSID.

Cantidad de variables

La base final está compuesta por variables provenientes de los tres archivos originales y por variables derivadas construidas durante el proceso de preprocesamiento. Las variables seleccionadas fueron aquellas consideradas relevantes para el análisis del consumo de psicofármacos y la posterior aplicación de algoritmos de clustering.

Diccionario de variables del dataset final

Variable	Descripción	Tipo de dato	Clasificación
DUPERSID	Identificador único de cada individuo	Entero/String	Cualitativa nominal
AGE20X	Edad del individuo	Entero	Cuantitativa discreta
SEX	Sexo del individuo	Categórica	Cualitativa nominal
MARRY20X	Estado civil	Categórica	Cualitativa nominal
EDUCYR	Años de educación completados	Entero	Cuantitativa discreta
POVCAT20	Categoría de ingresos según nivel de pobreza	Categórica	Cualitativa ordinal
EMPST53	Situación laboral	Categórica	Cualitativa nominal
INSCOV20	Cobertura médica	Categórica	Cualitativa nominal
MNHLTH53	Estado de salud mental autopercebido	Categórica	Cualitativa ordinal
RTHLTH53	Estado general de salud autopercebido	Categórica	Cualitativa ordinal
RACETHX	Grupo racial o étnico	Categórica	Cualitativa nominal
cantidad_condiciones	Cantidad de condiciones	Entero	Cuantitativa

Variable	Descripción	Tipo de dato	Clasificación
	médicas registradas		discreta
recetas_totales	Cantidad total de medicamentos prescritos	Entero	Cuantitativa discreta
benzodicepinas	Cantidad de benzodicepinas consumidas	Entero	Cuantitativa discreta
antidepresivos	Cantidad de antidepresivos consumidos	Entero	Cuantitativa discreta
hipnoticos	Cantidad de hipnóticos consumidos	Entero	Cuantitativa discreta
ansioliticos	Cantidad de ansiolíticos consumidos	Entero	Cuantitativa discreta
total_psicofarmacos	Total de psicofármacos consumidos	Entero	Cuantitativa discreta

Información relevante del dataset

El dataset integra información proveniente de distintas dimensiones relacionadas con la salud y el consumo de medicamentos:

- Características demográficas.
- Características socioeconómicas.
- Estado de salud general.
- Estado de salud mental.
- Condiciones médicas diagnosticadas.
- Medicamentos prescritos.
- Consumo específico de psicofármacos.

La combinación de estas dimensiones permite analizar posibles relaciones entre variables sociales, económicas y sanitarias con los patrones de consumo de medicamentos utilizados para el tratamiento de trastornos de ansiedad, depresión y alteraciones del sueño.

Origen de los datos

Los datos utilizados en este proyecto provienen de la encuesta pública Medical Expenditure Panel Survey (MEPS), desarrollada por la *Agency for Healthcare Research and Quality (AHRQ)*, organismo dependiente del Departamento de Salud y Servicios Humanos de los Estados Unidos.

MEPS es una de las principales fuentes de información sobre salud pública, utilización de servicios sanitarios, cobertura médica, gastos en salud y consumo de medicamentos. Los datos son de acceso público y se encuentran disponibles para investigación académica y científica.

Los archivos utilizados fueron descargados desde el portal oficial de MEPS durante el desarrollo del proyecto y posteriormente procesados mediante Python utilizando la biblioteca Pandas.

Descripción de los datasets originales (3)

Luego de una ardua y extensa navegacion por diferentes sitios de busqueda de datos, de la consulta con numerosas inteligencias artificiales, mi criterio fue la eleccion de estos tres set de datos , que para mi se inclinan mejor con lo que quiero trabajar y que tienen que ver con el objetivo principal. Se desestimaron numerosos set de datos y se trabajó con el apoyo de la inteligencia artificial en momentos donde el codigo se complicaba.

Para la construcción del dataset final se utilizaron tres archivos pertenecientes a MEPS.

1) Dataset H224 – Full-Year Consolidated Data File

Este archivo contiene información consolidada de las personas encuestadas durante el período de estudio.

Características principales

- 27.805 registros.
- 1.451 variables.

Información incluida

- Edad.
- Sexo.
- Estado civil.
- Nivel educativo.
- Situación laboral.
- Ingresos.
- Cobertura médica.
- Estado de salud general.
- Estado de salud mental.
- Características demográficas.

Este archivo constituye la base principal sobre la cual se realizó la integración de los demás datasets.

2) Dataset H222 – Medical Conditions File

Este archivo registra las condiciones médicas reportadas por los individuos encuestados.

Características principales

- 80.802 registros.
- 30 variables.

Información incluida

- Diagnósticos médicos.
- Códigos de clasificación de enfermedades.
- Condiciones de salud reportadas.
- Vinculación entre individuos y diagnósticos.

Este dataset permitió construir variables relacionadas con la cantidad de condiciones médicas asociadas a cada individuo.

3) Dataset H229A – Prescribed Medicines File

Este archivo contiene información sobre medicamentos prescritos a los participantes de la encuesta.

Características principales

- 303.394 registros.
- 66 variables.

Información incluida

- Nombre comercial del medicamento.
- Nombre genérico.
- Clasificación terapéutica.
- Cantidad de recetas.
- Información farmacológica.

Este dataset permitió identificar y clasificar medicamentos pertenecientes a las categorías de interés para el proyecto.

Proceso de integración y construcción del dataset final. (Este proceso también queda registrado en el jupyter notebook y va a estar incluido en los archivos en el Git “unificacion_psicofarmacos_fina.ipynb”).

La construcción del dataset final requirió una serie de tareas de preparación y preprocesamiento de datos.

Importación de los archivos

Se importaron los archivos H224, H222 y H229A utilizando la biblioteca Pandas en Python.

Exploración inicial

Se analizaron las dimensiones de cada dataset, los tipos de datos presentes y la calidad de la información disponible.

Selección de variables

Debido a la gran cantidad de variables presentes en los archivos originales, se seleccionaron aquellas consideradas relevantes para el estudio del consumo de psicofármacos y la caracterización de la población adulta.

Identificación de la clave de integración

Los tres datasets comparten la variable **DUPERSID**, identificador único asignado a cada individuo dentro de la encuesta. Esta variable fue utilizada para relacionar la información contenida en los distintos archivos.

Construcción de variables farmacológicas

A partir del archivo H229A se identificaron medicamentos pertenecientes a las siguientes categorías:

- Benzodiacepinas.
- Antidepresivos.
- Hipnóticos.
- Ansiolíticos.

Posteriormente se calcularon indicadores agregados por individuo, tales como:

- Cantidad total de recetas.
- Cantidad de benzodiacepinas consumidas.
- Cantidad de antidepresivos consumidos.
- Cantidad de hipnóticos consumidos.
- Cantidad de ansiolíticos consumidos.
- Total de psicofármacos consumidos.

Construcción de variables sanitarias

A partir del archivo H222 se calcularon indicadores relacionados con la cantidad de condiciones médicas registradas para cada individuo.

Integración de datasets

Los tres archivos fueron integrados mediante operaciones de unión utilizando la variable DUPERSID como clave principal.

Tratamiento de valores faltantes

Los registros sin información en determinadas variables derivadas fueron tratados mediante reemplazo por valores nulos o cero según correspondiera.

Generación del dataset final: “dataset_psicofarmacos_final.csv”

Finalmente se obtuvo un dataset consolidado que integra información demográfica, socioeconómica, médica y farmacológica, el cual será utilizado en la tercera etapa del proyecto para la aplicación de técnicas de aprendizaje automático.