

IMPORTO LAS LIBRERIAS

```
In [2]: import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import (
    accuracy_score,
    classification_report,
    confusion_matrix
)

import matplotlib.pyplot as plt
```

CARGO MI DATA SET

```
In [3]: df = pd.read_csv("dataset_ampliado_psicofarmacos_ml.csv")
df.head()
```

Out[3]:

	anio	provincia	grupo_etario	genero	consumo_psicofarmacos_pct	tasa_ansiedad_pct
--	------	-----------	--------------	--------	---------------------------	-------------------

0	2019	Buenos Aires	18-29	Mujer	11.58	37.0
---	------	--------------	-------	-------	-------	------

1	2019	Buenos Aires	18-29	Varon	8.37	41.0
---	------	--------------	-------	-------	------	------

2	2019	Buenos Aires	30-44	Mujer	12.99	20.5
---	------	--------------	-------	-------	-------	------

3	2019	Buenos Aires	30-44	Varon	10.19	23.7
---	------	--------------	-------	-------	-------	------

4	2019	Buenos Aires	45-59	Mujer	16.84	21.0
---	------	--------------	-------	-------	-------	------

CREO VARIABLE OBJETIVO (BINARIO)

```
In [5]: df["consumo_alto"] = np.where(
        df["consumo_psicofarmacos_pct"] > 15,
        1,
        0
    )

df["consumo_alto"].value_counts()
```

```
Out[5]: consumo_alto
1      292
0      268
Name: count, dtype: int64
```

CONVIERTO MIS VARIABLES (PARA ELLO LE PEDI AYUDA A LA IA)

```
In [6]: le = LabelEncoder()

df["provincia"] = le.fit_transform(df["provincia"])
df["grupo_etario"] = le.fit_transform(df["grupo_etario"])
df["genero"] = le.fit_transform(df["genero"])
df["acceso_salud_mental"] = le.fit_transform(df["acceso_salud_mental"])
df["impacto_postpandemia"] = le.fit_transform(df["impacto_postpandemia"])
```

DEFINO LAS VARIABLES

```
In [7]: X = df[
        [
            "anio",
            "provincia",
            "grupo_etario",
            "genero",
            "tasa_ansiedad_pct",
            "desempleo_pct",
            "consumo_alcohol_pct",
            "consumo_tabaco_pct"
        ]
    ]

y = df["consumo_alto"]
```

DIVIDO LOS DATOS ENTRENAMIENTO Y TEST

```
In [8]: X_train, X_test, y_train, y_test = train_test_split(
        X,
        y,
        test_size=0.3,
        random_state=42
    )
```

PRIMER MODELO : REGRESION LOGISTICA

ENTRENO EL MODELO

```
In [10]: modelo_log = LogisticRegression(max_iter=5000)

modelo_log.fit(X_train, y_train)
```

```
Out[10]:
```

▼ LogisticRegression ⓘ ?

► Parameters

PREDICCIONES

```
In [13]: pred_log = modelo_log.predict(X_test)
```

METRICAS

```
In [16]: report_log = classification_report(
    y_test,
    pred_log,
    output_dict=True
)

df_report_log = pd.DataFrame(report_log).transpose()

df_report_log
```

```
Out[16]:
```

	precision	recall	f1-score	support
0	0.884615	0.873418	0.878981	79.000000
1	0.888889	0.898876	0.893855	89.000000
accuracy	0.886905	0.886905	0.886905	0.886905
macro avg	0.886752	0.886147	0.886418	168.000000
weighted avg	0.886879	0.886905	0.886860	168.000000

```
In [29]: coeficientes = pd.DataFrame({
    "Variable": X.columns,
    "Coeficiente": modelo_log.coef_[0]
})

coeficientes = coeficientes.sort_values(by="Coeficiente")


plt.figure(figsize=(10,6))

plt.barh(
    coeficientes["Variable"],
    coeficientes["Coeficiente"],
    color="darkred"
)

plt.title("Importancia de Variables - Regresión Logística")
```

```
plt.xlabel("Coeficiente")

plt.show()
```



MATRIZ DE CONFUSION

```
In [22]: cm_log = confusion_matrix(y_test, pred_log)

df_cm_log = pd.DataFrame(
    cm_log,
    index=["Real Bajo", "Real Alto"],
    columns=["Pred Bajo", "Pred Alto"]
)

df_cm_log
```

```
Out[22]:
```

	Pred Bajo	Pred Alto
Real Bajo	69	10
Real Alto	9	80

```
In [30]: cm_log = confusion_matrix(y_test, pred_log)

plt.figure(figsize=(6,5))

plt.imshow(cm_log, cmap="Oranges")

plt.title("Matriz de Confusión - Regresión Logística")
plt.colorbar()

plt.xticks([0,1], ["Pred Bajo", "Pred Alto"])
plt.yticks([0,1], ["Real Bajo", "Real Alto"])

for i in range(cm_log.shape[0]):
    for j in range(cm_log.shape[1]):
        plt.text(
```


```

        j,
        i,
        cm_log[i, j],
        ha="center",
        va="center",
        color="black",
        fontsize=14,
        fontweight="bold"
    )

plt.xlabel("Predicción")
plt.ylabel("Valor Real")

plt.show()

```



MODELO 2 : ARBOL DE DECISION

ENTRENO EL MODELO

```

In [23]: modelo_tree = DecisionTreeClassifier(
            max_depth=4,
            random_state=42
        )

modelo_tree.fit(X_train, y_train)

```

```

Out[23]:
▼ DecisionTreeClassifier ⓘ ?
  ► Parameters

```

PREDICCIONES

```
In [24]: pred_tree = modelo_tree.predict(X_test)
```

METRICAS

```
In [25]: report_tree = classification_report(
    y_test,
    pred_tree,
    output_dict=True
)

df_report_tree = pd.DataFrame(report_tree).transpose()

df_report_tree
```

```
Out[25]:
```

	precision	recall	f1-score	support
0	0.781609	0.860759	0.819277	79.000000
1	0.864198	0.786517	0.823529	89.000000
accuracy	0.821429	0.821429	0.821429	0.821429
macro avg	0.822903	0.823638	0.821403	168.000000
weighted avg	0.825361	0.821429	0.821530	168.000000

```
In [28]: from sklearn import tree


plt.figure(figsize=(20,10))

tree.plot_tree(
    modelo_tree,
    feature_names=X.columns,
    class_names=["Bajo", "Alto"],
    filled=True
)

plt.title("Árbol de Decisión - Consumo de Psicofármacos")

plt.show()
```

Árbol de Decisión - Consumo de Psicofármacos



MATRIZ DE CONFUSION

```
In [26]: cm_tree = confusion_matrix(y_test, pred_tree)
```

```
df_cm_tree = pd.DataFrame(
    cm_tree,
    index=["Real Bajo", "Real Alto"],
    columns=["Pred Bajo", "Pred Alto"]
)
```

```
df_cm_tree
```

```
Out[26]:
```

	Pred Bajo	Pred Alto
Real Bajo	68	11
Real Alto	19	70

	Pred Bajo	Pred Alto
Real Bajo	68	11
Real Alto	19	70

```
In [31]: cm_tree = confusion_matrix(y_test, pred_tree)
```

```
plt.figure(figsize=(6,5))
```

```
plt.imshow(cm_tree, cmap="Oranges")
```

```
plt.title("Matriz de Confusión - Árbol de Decisión")
plt.colorbar()
```

```
plt.xticks([0,1], ["Pred Bajo", "Pred Alto"])
plt.yticks([0,1], ["Real Bajo", "Real Alto"])
```

```
for i in range(cm_tree.shape[0]):
    for j in range(cm_tree.shape[1]):
        plt.text(
            j,
            i,
            cm_tree[i, j],
            ha="center",
            va="center",
```


```

        color="black",
        fontsize=14,
        fontweight="bold"
    )

plt.xlabel("Predicción")
plt.ylabel("Valor Real")

plt.show()

```



CONCLUSION

En este trabajo se aplicaron técnicas de Machine Learning para analizar el consumo de psicofármacos en Argentina entre los años 2019 y 2025, utilizando variables sociales y demográficas relacionadas con salud mental, hábitos de consumo y contexto socioeconómico.

El objetivo principal fue construir modelos capaces de clasificar si un caso correspondía a un consumo alto o bajo de psicofármacos. Para ello se utilizaron dos modelos supervisados: Regresión Logística y Árbol de Decisión.

A partir de las métricas obtenidas, la Regresión Logística fue el modelo que presentó el mejor desempeño general. Alcanzó un accuracy cercano al 89%, además de valores elevados de precisión y recall para la clase de consumo alto.

Esto indica que el modelo logró identificar correctamente la mayoría de los casos positivos y cometer una menor cantidad de errores de clasificación, especialmente falsos negativos.

Por otro lado, el Árbol de Decisión obtuvo un rendimiento menor, con un accuracy cercano al 82% y una mayor cantidad de falsos negativos. Sin embargo, este modelo presentó la ventaja de ser más visual e interpretable, permitiendo comprender de manera más sencilla cómo las variables influyen en la toma de decisiones del modelo.

El análisis también permitió observar que variables como la ansiedad, el grupo etario y el consumo de alcohol y tabaco tuvieron una influencia importante en la predicción del consumo de psicofármacos, mostrando la relación existente entre factores sociales, emocionales y hábitos de consumo.

La Regresión Logística resultó ser el modelo más adecuado para este problema debido a su mayor capacidad predictiva y mejor equilibrio entre precisión y recall. Además, este trabajo permitió aplicar conceptos de análisis de datos, evaluación de modelos y aprendizaje automático sobre una problemática social real, demostrando cómo la inteligencia artificial puede utilizarse como herramienta de apoyo para el análisis e interpretación de fenómenos vinculados a la salud mental.

In []: